

数据集概览

#	数据集	细胞系	是否筛选
1	Xaira Therapeutics (X-Atlas/Orion)	HCT116、HEK293T	是
2	VCC 2025	H1	否
3	K562 Genome Wide (Replogle et al. 2022)	K562	是
4	GSE264667	Jurkat、HEPG2、HeLa	是
5	Primary CD4+ T	CD4+ T (Donor 1)	是

1. Xaira Therapeutics : HCT116、HEK293T

链接：[X-Atlas/Orion Genome-wide Perturb-seq \(figshare\)](#)

筛选标准：

扰动至少有 50 个细胞，且满足下面条件之一：

- DE 个数在前 5% (用 cell-eval 2 计算)
- 在比赛的 300 个扰动里面

然后：

- control 组筛选到 30,000 个细胞
- gene list 筛选掉不在比赛 gene list 中的 gene

2. VCC 2025 : H1

链接：[Arc Institute public data \(BigQuery\)](#)

筛选标准：不需要筛选。

3. K562 Genome Wide

链接：[Replogle et al. 2022 processed Perturb-seq datasets \(figshare\)](#)

筛选标准：

扰动至少有 50 个细胞，且满足下面条件之一：

- DE 个数 ≥ 50 (用 cell-eval 2 计算)
- 在比赛的 300 个扰动里面

然后：

- control 组筛选到 30,000 个细胞（如不足则不筛选）
- gene list 筛选掉不在比赛 gene list 中的 gene

4. Jurkat、HEPG2、HeLa

链接：[GEO GSE264667](#)

筛选标准：

扰动至少有 50 个细胞，且满足下面条件之一：

1. DE 个数 ≥ 50 （用 cell-eval 2 计算）
2. 在比赛的 300 个扰动里面

然后：

- control 组筛选到 30,000 个细胞（如不足则不筛选）
- gene list 筛选掉不在比赛 gene list 中的 gene

5. Primary CD4+ T

链接：[PMC3312336](#)

一共四个 Donor 的数据，训练只用了 Donor 1：

- D1_Rest
- D1_Stim8hr
- D1_Stim48hr

筛选标准：

扰动至少有 50 个细胞，且满足下面条件之一：

1. DE 个数在前 5%（用 cell-eval 2 计算）
2. 在比赛的 300 个扰动里面

然后：

- control 组筛选到 30,000 个细胞
- gene list 筛选掉不在比赛 gene list 中的 gene

训练集与测试集划分

- 训练集：除 H1 以外的所有数据
- 测试集：H1 中与比赛相交的 25 个扰动 + 随机选取的 75 个扰动（共 100 个），每个扰动 subsample 到 400 个细胞