

数据集概览 v3

11 个数据集 · 「处理后」数字全部由 06_schema.py 从最终 h5ad 实测 · 数据使用说明见第四章

一、总览

11 个数据集 · 逐条说明与数据使用说明见后文。表内所有「处理后」数字均由脚本从最终 h5ad 实测得到。

数据集	来源论文	细胞系	样本处理流程简介	测序平台	扰动类别	是否筛选
VCC 2025 官方数据 491,046 细胞 (训 221,273 · 验 98,927 · 测 170,846)	Virtual Cell Challenge 2025 (Arc Institute) 官方发布 非论文来源；数据托管在 Arc Virtual Cell Atlas 公共 GCS bucket 官网 virtualcellchallenge.org / 技术说明 arcinstitute.org/news/behind-the-data-virtual-cell-challenge	H1 人胚胎干细胞 (hESC) · CRISPRi (dCas9-KRAB)	先在 H1 上用 2,500 个 CRISPRi 扰动 做大规模预筛，再从中挑出 300 个 响应谱跨度大的靶基因 (用 ContrastiveVI+ 表征学习挑选，覆盖从响应剧烈到几乎无响应的各类模式)。构建体为 dual-guide (一个载体装两条 sgRNA, spacer 序列与克隆策略取自 Replogle, Bonnar et al. 2022)；低 MOI 慢病毒转导，保证每个细胞只带一个构建体。固定 + 探针法建库后按扰动拆成训/验/测三份，靶基因互不重叠。	10x Genomics Chromium Flex (固定 + 探针法) 48 个实验批次	CRISPRi (dCas9-KRAB) dual-guide (2 条 sgRNA/构建体) 靶基因 300 个 (训 150 · 验 50 · 测 100) 317 个 guide 对 (17 个基因有 2 对) + 38,176 非靶向对照细胞	否
HCT116 约 990 万比对细胞	Huang, Hsieh, Zhu et al. 2025, bioRxiv Xaira Therapeutics DOI 10.1101/2025.06.11.659105	HCT116 结直肠癌	FiCS Perturb-seq (Fix-Cryopreserve-scrRNAseq)：先固定、再冻存，攒批后统一上机，把「做实验」与「跑测序」解耦。tRNA 介导的慢病毒递送 dual-sgRNA 文库，两条 sgRNA 靶向同一基因以降低重排率。	10x Chromium Cell Ranger 8.0.1 GRCh38 2024-A bcl2fastq2 v2.2	CRISPRi (dCas9-KRAB) 全基因组文库 靶基因 18,903 个 · sgRNA 41,780 条 + 1,026 非靶向对照	是
HEK293T 约 2,155 万比对细胞	同上 同一论文的第二个细胞系	HEK293T 胚肾	同 HCT116，同一文库、同一流程，仅细胞系不同。	同上	同 HCT116	是
K562_gwps 1,989,578 细胞	Replogle et al. 2022, Cell 185(14):2559–2575 DOI 10.1016/j.cell.2022.05.013	K562_gwps K562 Genome-Wide (KD8) 慢性粒细胞白血病	CRISPRi 敲低，day 8 收获。dual-sgRNA 元件：一个载体上两条 U6 驱动 sgRNA 靶向同一基因，5% 非靶向对照。Poisson-Gaussian 混合模型做 guide 分配，随 GEM group 按每细胞 1,000 reads 下采样。	10x Chromium Cell Ranger 4.0.0 GRCh38 2020-A	CRISPRi (dCas9-BFP-KRAB) 全基因组文库 靶基因 9,866 个 sgRNA 2 条/靶基因 + 514 条对照 sgRNA	是
K562_essential 310,385 细胞	Replogle et al. 2022, Cell 185(14):2559–2575 DOI 10.1016/j.cell.2022.05.013 与 K562_gwps 同一论文，但为独立文库、独立实验	K562_essential (KD6) 慢性粒细胞白血病	CRISPRi 敲低，day 6 收获。文库范围收窄到 DepMap 20Q1 常见必需基因，与 K562_gwps 不是同一批细胞。dual-sgRNA 元件 + 5% 非靶向对照，Poisson-Gaussian 混合模型做 guide 分配，每细胞 800 reads 下采样，QC 门槛 ≥3,000 adjusted UMI、<20% mito。	10x Chromium Cell Ranger 4.0.0 GRCh38 2020-A	CRISPRi (dCas9-BFP-KRAB) 必需基因子库 靶基因 2,057 个 sgRNA 2 条/靶基因	是
Jurkat 262,956 细胞	Nadig, Replogle et al. 2025, Nat Genet 57(5):1228–1237 DOI 10.1038/s41588-025-02169-3 数据：GEO GSE264667	Jurkat Jurkat-Essential T 细胞白血病	CRISPRi，靶向 2,393 个常见必需基因。dual-sgRNA 文库 (2,688 个元件) + 5% 非靶向对照；转导后 day 3 分选、day 7 收获上机。pseudobulk 聚合后走 DESeq2，不做单细胞归一化。	10x Chromium 3' v3 + Feature Barcode CRISPR Cell Ranger 4.0.0 GRCh38 2020-A CG000184	CRISPRi (UCOE-EF1α-Zim3-dCas9-P2A-mCherry) 必需基因子库 2,393 个 sgRNA 元件 2,688 个	是
HepG2 145,473 细胞	SRA PRJNA1100571	HepG2 HepG2-Essential 肝细胞癌	同上，差异仅在抑制子：HepG2 用 KOX1 衍生的 dCas9-BFP-KRAB，Jurkat 用 ZIM3。	同 Jurkat	CRISPRi (UCOE-EF1α-dCas9-BFP-KRAB) 必需基因子库 2,393 个 · KOX1 衍生 sgRNA 元件 2,688 个	是

数据集	来源论文	细胞系	样本处理流程简介	测序平台	扰动类别	是否筛选
RPE1_essential 247,914 细胞	Replogle et al. 2022, Cell (原始) Nadig et al. 2025 (GSE264667 处理后版本)	RPE1_essential Replogle 必需因子文库 (RD7) 视网膜色素上皮	CRISPRi, 必需因子文库, day 7 收获。用 ZIM3-KRAB-dCas9 而非 KOX1-KRAB —— ZIM3 转录抑制更强, 是本文与该组其他数据的关键差异。其余文库设计、guide 分配与批次处理同 K562_gwps。	10x Chromium Cell Ranger 4.0.0 GRCh38 2020-A	CRISPRi (ZIM3-KRAB-dCas9) 必需因子文库 靶基因 2,393 个 sgRNA 2 条/靶基因	是
Adamson UPR 65,337 细胞	Adamson, Norman, Jost et al. 2016, Cell 167(7):1867–1882.e21 DOI 10.1016/j.cell.2016.11.048 Perturb-seq 原始论文	Adamson UPR K562 · 慢性粒细胞白血病	Perturb-seq 的起点。上游 CRISPRi 全基因组筛选命中一批 UPR 相关基因, 从中挑出候选做单基因敲低文库。核心创新: 把 sgRNA 身份编码进一段合成的多聚腺苷酸化转录本 (GBC), 使其与 mRNA 一起被 10x 3' 建库捕获。多引导载体一个质粒装 3 条完整 sgRNA 表达盒, 并用 hU6/mU6/bU6 × cr1/cr2/cr3 双层多样化抗重组。无药物处理, 分 10 个独立 Chromium 通道建库。	10x Chromium Single Cell 3' Cell Ranger 1.1 GBC 扩增子单独用 bowtie 比对	CRISPRi (dCas9-KRAB) 候选因子文库 靶基因 90 个 · construct 113 条 (含 3 条阴性对照, 7,295 细胞)	是
GSE132080 23,633 细胞	Jost et al. 2020, Nature Biotechnology 38(3):355–364 DOI 10.1038/s41587-019-0387-5 PMID 31932729	K562 滴定式衰减 sgRNA 文库 慢性粒细胞白血病	本文的核心是 把基因表达「调」到不同档位 , 而不是一次敲到底: 先大规模测量带错配 sgRNA 的活性、用深度学习归纳出错配→活性的规律, 据此合成紧凑文库 —— 每个基因配多条 relative_activity 从 1.0 到 0.07 不等 的衰减 sgRNA, 把细胞铺在表达量的连续谱上, 再看表型在哪个阈值发生跃变。本数据集是其中的 intermediate-activity 组, 分 3 个 Chromium 通道建库。	10x Chromium Single Cell 3' GEO GSE132080 (GPL20301)	CRISPRi (dCas9-KRAB) 滴定式: 每个基因多条不同活性的 sgRNA 靶基因 25 个 · sgRNA 128 条 + 10 种 neg_ctrl 非靶向对照 (2,446 细胞)	否
Primary CD4+ T 约 2,200 万细胞	Genome-scale perturb-seq in primary human CD4+ T cells Marson / Pritchard 实验室 bioRxiv 2025-12 · PubMed 42664972	Primary CD4+ T GWCD4i 原代人 CD4+ αβ T 细胞 · 健康供体 Leukopak 分离初始 CD4+ T	ZIM3-KRAB-dCas9 CRISPRi, 全基因组 sgRNA 文库, MOI ≈ 0.2。4 个供体 × 3 个条件 (Rest / Stim8hr / Stim48hr)。10x GEM-X Flex 探针法建库, pooled 样本按 probe barcode 拆回每个供体与刺激条件。GEO 未给作者的 guide 分配结果, 需自行做 guide calling。	10x GEM-X Flex 探针法 Cell Ranger v9.0.1 GRCh38 2024-A probe set	CRISPRi (ZIM3-KRAB-dCas9) 全基因组文库 靶基因 ≈11,300 个 (33,983 个扰动×条件对)	是

二、逐条说明

1. VCC 2025 官方数据：H1

链接：Arc Virtual Cell Atlas · virtual-cell-challenge/2025（公开 HTTPS，无需账号）

筛选标准：不需要筛选。官方直接发布，我方不做上游处理。

官方直接发布的数据，我方不做上游处理（不做 DEG 筛选、不筛基因），因此没有「处理后」数据——用的就是官方文件原样。
H1 是三个 split 共同的细胞系；在本方案的划分里，它充当测试集来源

数据源：Arc Virtual Cell Atlas 的公共 GCS bucket（storage.googleapis.com/arc-institute-virtual-cell-atlas/virtual-cell-challenge/2025），匿名 HTTPS 即可下载，无需账号。共 3 个 h5ad + 4 个 csv，约 34 GB；bucket 里另有原始 FASTQ 42 个文件约 5.8 TB（未下载）。本机路径 data/vcc_2025/{train,validation,test}/adata_*.h5ad。

数据集构成（本机实测）：

split	细胞数	靶基因	对照细胞	guide 对	批次	文件
训练 train	221,273	150	38,176	158	48	train/adata_Training.h5ad
验证 validation	98,927	50	38,176	54	48	validation/adata_Validation.h5ad
测试 test	170,846	100	38,176	105	48	test/adata_Test.h5ad
合计	491,046	300	38,176	317	48	三个 split 的基因数均为 18,080

官方说法已逐条与本机数据核对：

官方描述	核对	本机实测
300 个 CRISPRi 扰动，训 150 / 验 50 / 测 100	✓	靶基因数 150 / 50 / 100，并集正好 300
dual-guide，每个基因两条 sgRNA	✓	全部 guide_id 均为 A B 两条一组，无一例外；317 对 ≈ 634 条 sgRNA
只有 17 个靶基因带多于一个 guide 值	✓	训 8 + 验 4 + 测 5 = 17 个基因有 2 个 guide 对
10x Flex 化学、48 个实验批次	✓	三个 split 均为 48 个 batch，命名形如 Flex_1_01
每细胞 >50,000 UMI	✓	实测中位 53,912 / 54,312 / 54,126（训 / 验 / 测），三个 split 高度一致，全部 >50,000，也是本批数据里测序深度最高的

用这份数据时必须知道的两件事（本机实测发现）：

- 对照细胞在三个 split 里是同一批。38,176 个非靶向细胞的 barcode 100% 完全重合——直接把 train / validation / test 拼起来的话，这 38,176 行会被重复三遍（拼出 491,046 行，但其中只有 474,174 行是不同的扰动细胞 + 38,176 行对照）。对照是按设计共享的，不是三份独立对照。

• 三个 split 的靶基因完全不重叠（两两交集均为 0），所以「扰动要不要跨 split 去重」这个问题在 VCC 上不存在；但反过来，任何 split 内部都没有第二个 split 的靶基因做验证，跨 split 的泛化必须靠模型自己。

2. HCT116: HCT116

链接: X-Atlas/Orion Genome-wide Perturb-seq (figshare)

筛选标准: 扰动至少有 50 个细胞，且满足下面条件之一：DE 个数在前 5%（用 cell-eval 2 计算）；在比赛的 300 个扰动里面。然后：control 组筛选到 30,000 个细胞；gene list 筛选掉不在比赛 gene list 中的 gene。

本数据集尚未处理，处理前 → 处理后续补。原因：X-Atlas/Orion 数据尚未下载

3. HEK293T: HEK293T

链接: X-Atlas/Orion Genome-wide Perturb-seq (figshare)

筛选标准: 扰动至少有 50 个细胞，且满足下面条件之一：DE 个数在前 5%（用 cell-eval 2 计算）；在比赛的 300 个扰动里面。然后：control 组筛选到 30,000 个细胞；gene list 筛选掉不在比赛 gene list 中的 gene。

本数据集尚未处理，处理前 → 处理后续补。原因：X-Atlas/Orion 数据尚未下载

4. K562_gwps: K562_gwps • K562 Genome-Wide • (KD8)

链接: Replogle et al. 2022 processed Perturb-seq datasets (figshare)

筛选标准: 扰动至少有 50 个细胞，且满足下面条件之一：DE 个数 ≥ 50 （用 cell-eval 2 计算）；在比赛的 300 个扰动里面。然后：control 组筛选到 30,000 个细胞（如不足则不筛选）；gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	1,989,578	8,248	9,866	75,328	—	01_inspect overview.csv + 02_prepare summary	03_de 分片任务尚未跑完，04_filter 无产物，故「处理后」待补。
处理后	334,766	7,681	1,508	30,000	15.3%	k562gwps_filtered.h 5ad 06_schema 实测	对照:扰动 = 1:10.2 • 批次 267 个

5. K562_essential: K562_essential • (KD6)

链接: Replogle et al. 2022 processed Perturb-seq datasets (figshare)

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数 ≥ 50 (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞 (如不足则不筛选); gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	310,385	8,563	2,057	10,691	—	01_inspect overview.csv + 02_prepare summary	与 K562_gwps 靶基因重叠, 合并时需按数据集去重。
处理后	181,752	7,940	949	10,691	46.1%	k562ess_filtered.h5 ad 06_schema 实测	对照:扰动 = 1:16.0 • 批次 48 个

6. Jurkat: Jurkat • Jurkat-Essential

链接: GEO GSE264667

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数 ≥ 50 (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞 (如不足则不筛选); gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	262,956	8,882	2,393	12,013	—	01_inspect overview.csv + 02_prepare summary	基因名单命中率 93.3%。
处理后	143,810	8,284	946	12,013	39.5%	jurkat_filtered.h5a d 06_schema 实测	对照:扰动 = 1:11.0 • 批次 55 个

7. HepG2: HepG2 • HepG2-Essential

链接: GEO GSE264667

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数 ≥ 50 (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞 (如不足则不筛选); gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	145,473	9,624	2,393	4,976	—		基因名单命中率 93.8%。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
						01_inspect overview.csv + 02_prepare summary	
处理后	62,810	9,024	574	4,976	24.0%	hepg2_filtered.h5ad 06_schema 实测	对照:扰动 = 1:11.6 批次 56 个

8. RPE1_essential: RPE1_essential • Replogle 必需基因子库 • (RD7)

链接: Replogle et al. 2022 processed Perturb-seq datasets (figshare)

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数 ≥ 50 (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞 (如不足则不筛选); gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	247,914	8,749	2,393	11,485	—	01_inspect overview.csv + 02_prepare summary	基因名单命中率 94.4%。
处理后	150,836	8,260	1,060	11,485	44.3%	rpe1_filtered.h5ad 06_schema 实测	对照:扰动 = 1:12.1 批次 56 个

9. Adamson UPR: Adamson UPR

链接: scverse 镜像 adamson_2016_upr_perturb_seq.h5ad; GEO GSE90546 (GSM2406681)

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数 ≥ 50 (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞 (如不足则不筛选); gene list 筛选掉不在比赛 gene list 中的 gene。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	65,337	32,738	90	7,295	—	01_inspect overview.csv + 02_prepare summary	扰动组只计真实靶基因 (不含 non-targeting 对照); 无 guide 与非基因标签的细胞已剔除, 未并入对照 基因名单命中 17,323 / 32,738 (52.9%), 是各数据集中最低的 —— Adamson 的 var 是基因符号全集, 能被 vcc2026 名单命中的比例本来就低。
处理后	58,197	17,323	80	7,295	88.9%		对照:扰动 = 1:7.0 无有效批次

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
						adamson_filtered.h5ad 06_schema 实测	

10. GSE132080: K562 • 滴定式衰减 sgRNA 文库

链接: GEO GSE132080 (10X 矩阵 + cell_identities + sgRNA 活性表)

筛选标准: 扰动至少 50 个细胞, 且 FDR<0.05 的 DE 个数 ≥ 50; gene list 筛选掉不在 vcc2026 名单中的 gene。QC 按本数据集自己的口径在原始文件上做 (细胞级去 67 个 + 双细胞 1,421 个)。

阶段	细胞数	基因数	扰动组	对照细胞	扰动保留率	数据来源	备注
处理前	23,633	33,694	25	2,446	—	01_inspect overview.csv + 02_prepare summary	扰动组只计真实靶基因 (不含 non-targeting 对照); 无 guide 与非基因标签的细胞已剔除, 未并入对照 ★ 滴定式敲低: 每基因配多条活性递减的 sgRNA (1.0 → 0.07), 与其余数据集口径不同。基因名单命中率 95.7%。
处理后	20,944	17,743	24	2,326	96.0%	gse132080_filtered.h5ad 06_schema 实测	对照:扰动 = 1:8.0 • 批次 3 个

11. Primary CD4+ T: Primary CD4+ T • GWCD4i

链接: GEO GSE314342

筛选标准: 扰动至少有 50 个细胞, 且满足下面条件之一: DE 个数在前 5% (用 cell-eval 2 计算); 在比赛的 300 个扰动里面。然后: control 组筛选到 30,000 个细胞; gene list 筛选掉不在比赛 gene list 中的 gene。

本数据集尚未处理, 处理前 → 处理后续补。原因: 尚未做 guide calling, 01~04 未跑

三、训练集与测试集划分

训练集：除 H1 以外的所有数据。

测试集：H1 中与比赛相交的 25 个扰动 + 随机选取的 75 个扰动（共 100 个），每个扰动 subsample 到 400 个细胞。

注意：「除 H1 以外的所有数据」意味着训练池里混着 6 个不同细胞系、6 套批次编码、以及 1.7:1 到 16:1 不等的对照:扰动比例（见第四章 4.4）。跨数据集拼接前请先读那一节。

四、数据使用说明（Model-ready schema）

4.1 通用约定（所有数据集一致）

对象	含义	取值示例
obs['target_gene']	扰动靶基因；'non-targeting' 表示对照	ACLY / non-targeting
obs['batch']	批次（VCC 的 Flex 通道 / Replogle 与 GSE 的 gem_group）	Flex_1_01 / 27 / 39
obs['context']	细胞系 / 实验背景（H1, K562, Jurkat, HepG2, RPE1）	H1 / K562 / Jurkat / HepG2 / RPE1
obs['dataset']	来源标签（vcc2025 / replogle / gse264667 / adamson）	vcc2025 / replogle / gse264667 / adamson
X	原始 UMI counts，未归一化	
var_names	基因符号（已符号化，非 Ensembl ID）	
prefiltered	已按 DEG 数筛过扰动组 + 已按 vcc2026/gene_names.csv 筛过基因	

X 的存储格式各数据集不同，直接影响加载内存：

- 稠密数组（加载即占满内存）：K562_essential（181,752 × 7,940 → 约 5.8 GB）、RPE1_essential（150,836 × 8,260 → 约 5.0 GB）、Jurkat（143,810 × 8,284 → 约 4.8 GB）、HepG2（62,810 × 9,024 → 约 2.3 GB）
- 稀疏：K562_gwps（CSR）、Adamson UPR（CSC）、GSE132080（CSR）

若内存吃紧，读到稠密文件后可自行转稀疏（数据大部分为 0）。逐数据集的值见 dataset_schema.json 的 matrix.X_storage。

扰动组是按什么筛出来的：各数据集实际用的是 `n_deg_adj05 ≥ 50` —— 即只看 **FDR<0.05 的显著性**，没有加 **|log2FC|>1 的效应量过滤**。它直接决定「哪些扰动被当成有效的」。若需收紧，重跑 04_filter 时加 `--deg-col n_deg_abs_lfc1` 即可（03 的 DE 两列都已算好，不必重跑）。

```
import anndata as ad
a = ad.read_h5ad("../jurkat_filtered.h5ad")
pert = a.obs["target_gene"] # 扰动; 'non-targeting' 是对照
is_ctl = pert == "non-targeting"
X = a.X # 原始 UMI counts，未归一化 —— 归一化请自行做
gene = a.var_names # 基因符号（已符号化，不是 Ensembl ID）
```

4.2 各数据集：列在哪里、能不能用

数据集	文件	维度	扰动列	批次列	细胞系列	dataset 标签	该数据集特有的可用列
K562_gwps	k562gwps_filtered.h5ad	334,766 × 7,681	target_gene 1508 组 + 对照	batch 267 个值 1, 10, 100...	context K562	dataset replogle	gem_group、gene_id、transcript、gene_transcript、sgID_AB、mitopercent、UMI_count、z_gemgroup_UMI、core_scale_factor、core_adjusted_UMI_count

数据集	文件	维度	扰动列	批次列	细胞系列	dataset 标签	该数据集特有的可用列
K562_essential	k562ess_filtered.h5ad	181,752 × 7,940	target_gene 949 组 + 对照	batch 48 个值 1, 10, 11...	context K562	dataset repogle	gem_group、gene_id、transcript、gene_transcript、sgID_AB、mitopercent、UMI_count、z_gemgroup_UMI、core_scale_factor、core_adjusted_UMI_count
Jurkat	jurkat_filtered.h5ad	143,810 × 8,284	target_gene 946 组 + 对照	batch 55 个值 1, 10, 11...	context Jurkat	dataset gse264667	gem_group、gene_id、transcript、gene_transcript、sgID_AB、mitopercent、UMI_count、z_gemgroup_UMI
HepG2	hepg2_filtered.h5ad	62,810 × 9,024	target_gene 574 组 + 对照	batch 56 个值 1, 10, 11...	context HepG2	dataset gse264667	gem_group、gene_id、transcript、gene_transcript、sgID_AB、mitopercent、UMI_count、z_gemgroup_UMI
RPE1_essential	rpe1_filtered.h5ad	150,836 × 8,260	target_gene 1060 组 + 对照	batch 56 个值 1, 10, 11...	context RPE1	dataset repogle	gem_group、gene_id、transcript、gene_transcript、sgID_AB、mitopercent、UMI_count、z_gemgroup_UMI、core_scale_factor、core_adjusted_UMI_count
Adamson UPR	adamson_filtered.h5ad	58,197 × 17,323	target_gene 80 组 + 对照	batch 常数 K562	context K562	dataset adamson	perturbation、read count、UMI count、cell_line、celltype、ncounts、ngenes、percent_mito、percent_ribo、nperts
GSE132080	gse132080_filtered.h5ad	20,944 × 17,743	target_gene 24 组 + 对照	batch 3 个值 1, 2, 3...	context K562	dataset gse132080	—

VCC 2025 官方数据 为官方直接发布的数据，我方不做上游处理，故不在上表 —— 用的是官方文件原样（obs 自带 target_gene / guide_id / batch）。

待补数据集（尚无 04_filter 产物，列信息暂时无从实测，故未列入上表）：HCT116、HEK293T、Primary CD4+ T。跑完 04 后重跑 06_schema.py 与本章即可自动补齐。

4.3 数据集特有列字典

列名	说明
UMI_count Adamson UPR	guide 的 UMI 数（仅 Adamson）
UMI_count K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	该细胞的总 UMI（Repogle 原始计数口径）
cell_line Adamson UPR	细胞系；★ 只有 Adamson 有这一列，其余数据集请统一用 context
celltype Adamson UPR	细胞类型（仅 Adamson，全为 lymphoblasts）
core_adjusted_UMI_count K562_gwps、K562_essential、RPE1_essential	乘过 core_scale_factor 的 UMI 数；仅在要复现原文时用
core_scale_factor K562_gwps、K562_essential、RPE1_essential	Repogle 原文的可选归一化系数（按 gem_group 估计）

列名	说明
gem_group K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	10x Chromium 通道号，已被复制到 canonical 的 batch 列
gene_id K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	靶基因的 Ensembl ID
gene_transcript K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	guide 分配的唯一标识，形如 <数字>_<基因>_<元件>_<Ensembl>
mitopercent K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	线粒体基因占比；★ 原值是 0-1 的比例，不是百分数
ncounts Adamson UPR	该细胞的基因水平计数总和（与 X 行和不一定相等，见下）
ngenes Adamson UPR	该细胞检出的基因数
nperts Adamson UPR	不是「多重扰动数」：本文件里它与标签一一对应（0↔无 guide / 1↔'*/2↔真实 construct，前两类均已整组剔除），是 scPerturb 的产物
percent_mito Adamson UPR	线粒体基因占比，已是百分数 0-100
percent_ribo Adamson UPR	核糖体基因占比，已是百分数 0-100
perturbation Adamson UPR	原始 construct ID（如 OST4_pDS353），不是规范靶基因列；请用 target_gene
read_count Adamson UPR	guide 的 reads 数（仅 Adamson）
sgID_AB K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	guide 对（含靶向位置与 P1/P2 元件），与 gene 列无关
transcript K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	sgRNA 的启动子/元件型别（P1P2 / P1 / P2 / non-targeting）
z_gemgroup_UMI K562_gwps、K562_essential、Jurkat、HepG2、RPE1_essential	UMI 总数在该 gem_group 内的 z-score，可用于挑异常孔

4.4 关键信息确认

① guide calling 与「无 guide 细胞」

核心区分：「细胞里没有 sgRNA」和「细胞里有 sgRNA 但它不靶向任何基因」是两回事：

• 对照（non-targeting）：有 guide，只是 guide 序列不靶向任何基因。这是设计好的参照组，必须保留。

• 无 guide 细胞：一个 sgRNA 都没检出。既没被扰动、也不构成对照——应整组剔除。把它当对照会系统性地拉低对照的表达谱，污染每一个扰动组的 DE 结果。

数据集	guide calling 状态	无 guide 细胞	说明
VCC 2025 · H1	官方已做 guide_id	无	train / validation / test 三个文件各查一遍：每个细胞都有 guide_id（A B 双 sgRNA），无空值、无「未分配」类别。对照 38.6%，是官方设计的高对照比例。
Replogle K562_gwps / K562_ess / RPE1	原文已做 sgID_AB	无	每个细胞都有 gene / sgID_AB / gene_transcript 归属，无空值。gene 的取值数（如 K562ess 2,058）= 2,057 靶基因 + non-targeting，没有「未分配」桶。对照占比 3.4–4.6%，与文库设计的 5% 非靶向吻合，不像被无 guide 细胞稀释过。
GSE264667 Jurkat / HepG2	原文已做 同 Replogle schema	无	同上。对照 4.6% / 3.4%。
Adamson UPR	原文已做 perturbation + guide reads	有：2,613 个 另有 101 个 非基因标签（ '*' ）	本文件的 nperts 只有三个取值，正好一一对应三类细胞，前两类都不是对照，已整组剔除： nperts == 0（2,613 细胞）： perturbation / read count / UMI count 三列同时为 NaN（两判据实测 1:1 吻合）→ 一个 sgRNA 都没检出 → 剔除， reason = no_guide ； nperts == 1（101 细胞）： 标签为 '*'，非基因、非对照 → 剔除， reason = non_gene_label ； nperts == 2（62,623 细胞）： 真实 construct → 保留（其中 3 个（mod）是阴性对照，见下）。 → 最终文件里只剩 nperts == 2（58,197 细胞）；对照从 9,908 降到 7,295（= 3 个（mod）construct）。（明细见 02_prepare 的 _dropped_perts.csv）
Primary CD4+ T	尚未做 （数据齐备）	待定	GEO 的 *_filtered_feature_bc_matrix.h5 带 CRISPR Guide Capture 通道：每个文件 45,402 个 feature = 18,130 个基因 + 27,272 条 guide（形如 ARMCS-1）。即 guide 计数在矩阵里，可以自行做 guide calling，只是我方还没做。做完后同样要剔除无 guide 细胞，别并入对照。
GSE132080 K562 滴定	原文已做 guide_identity	有：25 个无 guide + 296 个非基因标签	GEO 直接提供 guide_identity，共 133 种（= 123 个真实基因 + 10 个 neg_ctrl）。本方案按基因合并成 25 组，故 25 个无 guide 细胞与 296 个非基因标签（ '*' ）细胞已剔除、未并入对照。原始 guide 身份保留在 obs['guide_identity']，需要时可拆回 guide 粒度。
HCT116 / HEK293T	未下载	未知	X-Atlas/Orion 数据尚未下载，无从判断。下载后按同样标准核查。

Adamson 的靶基因数与对照组——已用数据定论。把 113 个 construct（100 _pDS + 13 _pBA）剥掉后缀得 93 个名字，其中 3 个是（mod）→ 90 个真实靶基因；对照 = 3 个（mod）construct，共 7,295 个细胞（63(mod) 6010 + Gal4-4(mod) 1283 + 62(mod) 2）。

验证方式：以文献确认的非靶向对照 Gal4-4(mod) 为参照逐个算 DE——63(mod) 有 0 个 |log2FC|>1 基因，是全部 96 组里唯一一个 0（次低的 1 个，真扰动组中位 26、最高 744）；组间 pseudobulk 相关 63(mod) × Gal4-4(mod) = 0.9965，为所有配对最高。两项证据一致，63(mod) 就是对照。62(mod) 只有 2 个细胞，无法检验。

两个易错点：① _pBA 结尾的 construct 不都是对照——13 个里有 10 个是真扰动（ATF4×3 / EIF2AK3×2 / ERN1×2 / XBP1×2 / ATF6×1），只看后缀名会把它们误判成对照；② '*' 那 101 个细胞相对 Gal4-4(mod) 有 506 个 |log2FC|>1 基因，绝不是对照，支持整组剔除。

本文件的基因数与 construct 数与原文该实验的规模对不上（scPerturb 版重新整理过，标签口径与原文不一致，且没有 gem_group 列，无法拆回原文的 10 个 Chromium 通道）。

② 质控（是否需要统一标准再控一遍）

数据集	上游基础质控	依据
VCC 2025 · H1	已做	官方 var 带 scanpy 质控指标（ <code>n_cells_by_counts</code> / <code>pct_dropout_by_counts</code> / <code>total_counts</code> ）。无低质量尾部：UMI 最小 19,982 、基因最小 5,670 。
Replogle K562_gwps / K562_ess / RPE1	已做	obs 自带 <code>UMI_count</code> / <code>mitopercent</code> / <code>core_adjusted_UMI_count</code> （原文还按 GEM group 做了 UMI 调整）。原始发布文件实测：UMI 最小 557（gwps）/ 1,457（RPE1）/ 1,782（ess），基因数最小 323–713， UMI<500 与基因数<200 的细胞均为 0.0%，也没有 mito>20% 的细胞 ——上游按 UMI 与 mito 都卡过。
GSE264667 Jurkat / HepG2	已做	与 Replogle 同一套 schema 与流程（ <code>UMI_count</code> / <code>mitopercent</code> / <code>z_gemgroup_UMI</code> ）。原始文件实测：UMI 最小 1,641 / 2,881，基因数最小 627 / 701，同样无低计数与高 mito 尾部。
Adamson UPR	部分	obs 自带 <code>ncounts</code> / <code>ngenes</code> / <code>percent_mito</code> / <code>percent_ribo</code> ，低计数尾部已清（原始文件 UMI 最小 3,179、基因数最小 462）。 但没卡 mito ：原始文件里仍有 0.3% 的细胞 mito>20% （最高 82%）。这是六个数据集中唯一一个 mito 未被过滤的。
Primary CD4+ T	未知	GEO 给的是 Cell Ranger <code>filtered</code> 矩阵——Cell Ranger 已做细胞判定与基础过滤，但作者后续是否再质控，无从判断。处理后需自查。
GSE132080 K562 滴定	我方做的 （上游未做）	GEO 给的是原始计数矩阵， <code>uns['source']</code> 里明确注明「未经质控」——是这批数据里 唯一由我方执行 QC 的。在原始文件上按本数据集口径跑 <code>02_prepare --qc</code> ：细胞级过滤（ <code>min_features</code> 400 / <code>max_features</code> 7000 / <code>mito</code> ≤20%）去掉 67 个细胞 （3 个 batch 保留率 99.6–99.8%），双细胞检测再去掉 1,421 个 。
HCT116 / HEK293T	未知	未下载，无从判断。

除 GSE132080 外，我方没有再质控（`--qc` 默认关闭；GSE132080 是唯一例外，因为上游没做）。对其余数据集不 QC 的理由是**没有必要、而且做不到统一**：

- **没有可删的东西**。六个数据集的最终文件里，UMI<500 与基因数<100 的细胞占比**全是 0.0%**，最小 UMI 也都在 900 以上（VCC 更是 19,982）。再按 UMI / 基因数筛是空操作。
- **统一阈值不可能合适**。各数据集测序深度差 5 倍以上——VCC 中位 **54,312** UMI/细胞，Adamson 只有 **9,915**。同一个 `min_counts` 对高深度数据集是空操作，对低深度数据集就是误删。
- **mito 尤其不能用统一阈值**——这个指标依赖基因集口径。我们的文件按 `vcc2026/gene_names.csv` 只保留了部分基因，分母变小会把 mito% 整体抬高：同一批 K562_essential 细胞，上游全转录组口径中位 **10.6%**，在我们的过滤后文件上算出来是 **15.3%**。若照搬「mito<20%」，会删掉 **11.9%** 上游认为完全干净的细胞。（唯一例外是 VCC，它是官方原样、未经过我方筛基因，口径没有这个问题。）

结论：上游已质控的一律不再 QC（GSE132080 是唯一例外——上游没做，我方在其原始文件上按本数据集口径补做，正是下面这条规矩的正确用法）。今后若要控 mito，也只能在原始文件上、按各数据集自己的口径做（如 Adamson 那 0.3% 的 mito>20% 细胞），不能在我们的过滤后文件上做。